Commandes et objets de base

Vincent Guillemot
Amaury Vaysse

Bien se préparer à coder

- Créer un projet dans ce dossier :
  - Bien réfléchir au nom de ce projet
  - Bien réfléchir à l'endroit où ce projet sera situé
- Créer un script
- Savoir où sont les données, et sous quel format
- Savoir ce que l'on veut faire !

C’est parti pour les commandes de base !

Le(s) prompt(s)

- `>` : R attend une commande à exécuter
- `+` : la commande qui a été entrée n'est pas complète car
  - il manque une parenthèse fermante
  - il manque un crochet fermant
  - il manque une accolade fermante
- : la commande est en cours de traitement. On peut l'arrêter en cliquant sur le bouton "Stop"

Une commande, c'est quoi ?

C'est une séquence d'opérations appliquées à des objets ou des valeurs qui sera donnée au compilateur de R pour interprétation.

- "opération" : permet de transformer des entrées en sorties, p.ex. : la fonction `log`;
- "objets" : structures de données, p.ex. : plus tard ;
- "valeurs" : des briques de base, p.ex. : la valeur `0`.

Une fois la commande écrite dans la console, on l'exécute en appuyant sur "Entrée".

Exercice

Exécutez les commandes suivantes :

1. `1 + 1`
2. `1+1`
3. `log(10)`
4. `log10(10)`

Remarquez l'utilisation des parenthèses pour appliquer une fonction !

Opérations de base

On peut effectuer toutes les opérations de base en R :

- addition (`+`), soustraction (`-`), multiplication (`*`), division (`/`), exponentiation (`**` ou `^`)…

appliquer les fonctions mathématiques de base :

- logarithme (`log`, `log2`, `log10`), exponentielle (`exp`) sinus (`sin`), cosinus (`cos`), tangente (`tan`)

On peut combiner les opérations et les fonctions, et gérer les priorités avec des parenthèses !

Exercice

Imaginez une commande incluant le plus d’opérations et de fonctions de base et dont le résultat serait 2 !

Un opérateur bien pratique, le `:`

Comment créer une suite d'entier ?

- `c(1, 2, 3, 4)`
- `seq(1, 4, 1)`
- `1:4`

L'opérateur `:` est très utilisé en R. Sa syntaxe est la suivante

- i`:`j va créer une suite d'entiers de i à j. Les entiers peuvent être négatifs ou positifs, et on peut peut avoir $\mathrm{i} < \mathrm{j}$ ou $\mathrm{i} > \mathrm{j}$, ou même $\mathrm{i} = \mathrm{j}$.

Attention à bien mettre des **parenthèses** dans le cas d'entiers négatifs!

Exemples

- `3:7` : les entiers de 3 à 7
- `7:3` : les entiers de 7 à 7
- `-3:7` : les entiers de -3 à 7
- `-3:-7` : les entiers de -3 à -7
- `-(3:7)` : les entiers de -3 à -7

Exercice

1. Créez un vecteur d'entiers de 0 à 3
2. Créez un autre vecteur d'entiers de 3 à 1
3. *Combinez* ces deux suites pour obtenir le vecteur suivant :

3	2	1	0	1	2	3

Assignation avec <-

Comment “sauvegarder” ces objets ?

En utilisant l’**opérateur d’assignation**

Utilisation de l'opération d'assignation

- A gauche : l'objet que l'on veut créer
- A droite : sa définition
- Lecture de l'opération : "assigner à cet objet (à gauche) le résultat de cette commande (à droite)"
- Assigner deux fois de suite écrasera la première valeur assignée
- Alternative : =
- Exemples : `a <- 1; b <- 1:10; a <- 2` etc.

Les noms d'objets

Règles absolues :

- Commence par une lettre ou un point, si le premier caractère est un point, le deuxième ne peut pas être un chiffre,
- Pas d'espace
- Pas de caractères correspondant à des opérations (`+`, `-`, `*`, `/`, `^`, `**`, etc.)
- Les minuscules et les majuscules sont différentes !
- Certains "mots-clefs" sont strictement interdits (`NA`, `TRUE`, `FALSE`, `for`, `if`, `else` etc.)
- MAIS on peut utiliser un nom d'objet qui existe déjà !

Bonnes pratiques :

- Utiliser un nom qui a du sens
- Ne pas utiliser des noms d'objets qui existent déjà et que l'on ne souhaite pas écraser !

Mini exercice

1. Créez un vecteur d'entiers de 0 à 3, appelez le `a`
2. Créez un autre vecteur d'entiers de 3 à 1, appelez le `b`
3. *Combinez* ces deux vecteurs pour obtenir un vecteur `ab` selon le modèle suivant :

3	2	1	0	1	2	3

Opérations

On peut appliquer des opérations à ces “vecteurs” !

```
a <- 1:5
a + 1
#> [1] 2 3 4 5 6
a * 2
#> [1]  2  4  6  8 10
```

Ces “vecteurs” sont des **objets**.

Les Objets

Classes d'objets

Nom	Appelation officielle	Exemple
Vecteur	???	`1:10`
Facteur	`factor`	`gl(2, 2)`
Matrice	`matrix`	`matrix(1:4, 2, 2)`
Tableau	`data.frame`	`mtcars`
Liste	`list`	`list(a = 1, b = 1:10, c = "Hello!")`
Fonction	`function`	`sin`, `exp`, `log`

Pour connaître la classe d'un objet : `class(objet)`.

Types de données

Nom	Appellation officielle	Exemple
Entier ($\mathbb{Z}$)	`integer`	`1:10`, (ou `1L`)
Réel ($\mathbb{R}$)	`double`	`2.3`, `1/3`, etc...
Caractères	`character`	`month.name`, `"Bonjour"`
Booléen	`logical`	`TRUE`

Bouh les quoi ?

MATH., néol. Qui est relatif aux théories du logicien et mathématicien anglais George Boole.

– *Trésor de la Langue Française informatisé*

- `TRUE` (ou bien `T`) et `FALSE` (ou bien `F`)
- Résultat d'une comparaison : `==`, `!=`, `<`, `>`, `<=`, `>=`
- Opérations logiques : `!`, `&`, `|`, `xor`

Exercice

1. Effectuez les opérations suivantes :

- `1 == 2`
- `!(5 > -6)`
- `(1 <= 10) | (1 > 0)`

1. Prédisez le résultat de la commande suivante : `log(1) != 0`

“Classification” des objets

Les objets qui ne contiennent qu’un seul type de données : vecteurs et matrices.

Les objets pouvant contenir des données mixtes : tableaux et listes.

La flexibilité a un coût : on ne peut plus faire certaines opérations !

Les objets ayant des “dimensions” : vecteurs, tableaux et matrices

Les objets pour qui cela ne signifie rien ou presque : listes et fonctions

Petit détour par les tableaux

```
data("fruits", package = "minidebuter")
head(fruits)
#> # A tibble: 6 × 18
#>   nom    groupe Energie   Eau Proteines Glucides Lipides Sucres Fructose Fibres Calcium Magnesium
#>   <chr>  <chr>    <dbl> <dbl>     <dbl>    <dbl>   <dbl>  <dbl>    <dbl>  <dbl>   <dbl>      <dbl>
#> 1 Abric… crus       194  87.1      0.81     9.01    0.25    6.7      1.3    1.7    15          8.4
#> 2 Abric… secs      1010  24.7      2.88    59.1     0.5    34.3     10.6    8.3    71         41
#> 3 Ananas exoti…     304  81.3      0.94    15.1     0.25   14.9      2.8    2.4     6.3       15
#> 4 Banane exoti…     383  75.8      1.06    19.7     0.25   15.6      3.8    2.7     5.1       28
#> 5 Canne… secs      1410  14.6      0.25    76.4     1      72.8     28.4    5.7     8          3.9
#> 6 Cerise crus       235  85.7      0.81    13       0.25   10        4.6    1.6     9.9        8.8
#> # ℹ 6 more variables: Phosphore <dbl>, Potassium <dbl>, Zinc <dbl>, BetaCarotene <dbl>,
#> #   VitamineE <dbl>, VitamineC <dbl>
dim(fruits)
#> [1] 51 18
nrow(fruits)
#> [1] 51
ncol(fruits)
#> [1] 18
fruits
#> # A tibble: 51 × 18
#>    nom   groupe Energie   Eau Proteines Glucides Lipides Sucres Fructose Fibres Calcium Magnesium
#>    <chr> <chr>    <dbl> <dbl>     <dbl>    <dbl>   <dbl>  <dbl>    <dbl>  <dbl>   <dbl>      <dbl>
#>  1 Abri… crus       194  87.1      0.81     9.01    0.25    6.7      1.3    1.7    15          8.4
#>  2 Abri… secs      1010  24.7      2.88    59.1     0.5    34.3     10.6    8.3    71         41
#>  3 Anan… exoti…     304  81.3      0.94    15.1     0.25   14.9      2.8    2.4     6.3       15
#>  4 Bana… exoti…     383  75.8      1.06    19.7     0.25   15.6      3.8    2.7     5.1       28
#>  5 Cann… secs      1410  14.6      0.25    76.4     1      72.8     28.4    5.7     8          3.9
```

Importer des données en R

- Des données de *packages* : `data`
- Des données au format R (`RData`) : `load`
- Des données “tabulées” : `read.table`
- Des données Excel : `readxl::read_excel`
- Des données Stata, SPSS, images etc.

Les données “de R”

- Utiliser la commande `data()` pour avoir une liste (presque ?) exhaustive.
- Bonne pratique : pour charger un jeu de données, utiliser la commande complète `data("nom_des_data", package = "nom_du_package")`
- Mais ces alternatives fonctionnent également :
  - `data(mtcars)`
  - `DNase`
  - `library(ggplot2) ; data(diamonds)`

Utilisation des guillemets

- Obligation : quand l'argument doit être une chaîne de caractères
- Oubli : `library`, `require`, `data`
- Guillemets simples : fonctionnent comme les guillemets doubles. Ex.: `"bonjour"` est équivalent à `'bonjour'`.
- Le "backtick" ou "backquote" : "`"

Bref, c'est quoi un `tibble` ?

Mise à jour de la table des classes d'objets !

Nom	Appelation officielle	Exemple
Vecteur	???	`1:10`
Facteur	`factor`	`gl(2, 2)`
Matrice	`matrix`	`matrix(1:4, 2, 2)`
Tableau	`data.frame`	`mtcars`
Tableau	`tibble`	`fruits`
Liste	`list`	`list(a = 1, b = 1:10, c = "Hello!")`
Fonction	`function`	`sin`, `exp`, `log`

Explorer les données `fruits`

```
[ ]
```

```
[ , ]
```

```
[ [ ] ]
```

```
$
```

Sur quels objets les utiliser ?

Opérateur	Vecteurs	Matrices	Tableaux	Listes
`[ ]`	x		x	x
`[ , ]`		x	x	
`[[ ]]`			x	x
`$`			x	x

L'opérateur de sélection classique : `[ , ]`

- Pour sélectioner la première ligne : `fruits[1, ]`
- Pour sélectionner la deuxième colonne : `fruits[, 2]`
- Pour enlever la troisième ligne : `fruits[-3, ]`
- Pour enlever la quatrième colonne : `fruits[, -4]`

Exercice

Comment faire pour sélectionner les fruits numéro 1, 3 et 5 ?

Je veux deux solutions : une “normale” et une “créative” !

Sélectionner plusieurs lignes / colonnes

- Pour sélectioner les lignes 1 et 3 : `fruits[c(1, 3), ]`
- Pour sélectionner les colonnes 2 et 4 : `fruits[, c(2, 4)]`
- Pour enlever les lignes 5 et 7 : `fruits[-c(5, 7), ]`
- Pour enlever les colonnes 6 et 8 : `fruits[, -c(6, 8)]`

De l'utilité des deux points

Pour sélectionner une plage entière de lignes ou de colonnes adjacentes :

- Pour sélectionner les lignes 11 à 17 : `fruits[11:17, ]`
- Pour sélectionner les colonnes 3 à 5 : `fruits[, 3:5]`
- Pour enlever les trois premiers fruits : `fruits[-(1:3), ]`
- Pour enlever les cinq premières variables : `fruits[, -(1:5)]`

Exercice

Que se passe-t-il quand on oublie les parenthèses dans la commande `fruits[-(1:3), ]` ? Commentez !

Faites de même avec le jeu de données `mtcars`.

Pour extraire une seule colonne : le `$`

La syntaxe `donnees$cible` permet de sélectionner la colonne `cible` du tableau `donnees`.

- Par exemple : `fruits$Eau`
- Autre exemple : `fruits$groupe`

N.B: la selection de la colonne sert soit à récupérer le contenu de cette colonne soit à créer la colonne ou remplacer son contenu. Par exemple :

```
fruits$num <- 1:nrow(fruits)
```

Exercice

Extrayez la colonne de la teneur en sucres de la table des fruits… de deux façons différentes !

Créez un objets contenant la teneur en sucres : quelle est la classe de cet objet ?

Les vecteurs…

- … sont “unidimensionnels”
- … ont une classe qui est égale au type de données qu’ils contiennent (R !!!)
- … sont indexés avec des crochets simples

Exemples :

- `i <- 1:10`
- `eau <- fruits$Eau`
- `eau[i]`

Exercice

Créez un vecteur `groupe` contenant les groupes de fruits. Donnez deux façons différentes d'extraire les dix premières valeurs de ce vecteur.

Extraction avec des Booléens

Comment extraire les fruits … * dont la teneur en eau est supérieure à 60 ? * exotiques ? * secs contenant moins de 40g/100g de sucres ?

Réponse : en utilisant des vecteurs booléens

1. Créer le vecteur de booléens `fruits$Eau >= 60`
2. Utiliser le résultat dans les crochets carrés `fruits[fruits$Eau >= 60, ]`

Ne pas oublier la virgule !

Le principe

Pour un vecteur `v` :

- `v[bool]` extrait les valeurs de `v` pour lesquelles `bool` est vrai (`TRUE`).
  Contrainte : `v` et `bool` doivent contenir **le même nombre d'élements**.

Pour un tableau `tab` :

- `tab[brow, ]` pour extraire les lignes
- `tab[, bcol]`
- Contrainte 1 : `brow` doit avoir autant d'éléments que `tab` de lignes
- Contrainte 2 : `bcol` doit avoir autant d'éléments que `tab` de colonnes

Attention

Vous verrez souvent des opérations logiques à l'intérieur des crochets carrés : cela permet d'aller plus vite !

Par exemple, en deux étapes :

1. `bool <- fruits$groupe == "secs" & fruits$Sucres < 40`
2. `fruits[bool, ]`

Devient, en une étape :

- `fruits[fruits$groupe == "secs" & fruits$Sucres < 40, ]`

Attention bis

On peut combiner deux méthodes d'extraction de données pour un tableau : une sur les lignes et une sur les colonnes !

Par exemple : `tab[brow, icol]`, où `brow` est un vecteur de booléens et `icol` un vecteur d'indices.

Exercice

Construisez la sous-table contenant la teneur en protéines, en glucides et en lipides des fruits secs.

Les objets nommés

En R, on peut donner des “noms”…

- aux éléments d’un vecteur,
- aux lignes d’un tableau ou d’une matrice,
- aux colonnes d’un tableau ou d’une matrice,
- aux éléments d’une liste

Pourquoi ? Pour pouvoir disposer d’une nouvelle méthode d’extraction de données !

Pour un tableau

On utilise :

- `rownames(tab)` pour connaître le nom des lignes
- `colnames(tab)` pour connaître le nom des colonnes

Et, en bonus, on peut :

- changer les noms des lignes `rownames(tab) <- new1`
- changer les noms des colonnes `colnames(tab) <- new2`

Et, en super bonus, on peut :

- modifier quelques noms de lignes `rownames(tab)[sel1] <- new1`
- modifier quelques noms de colonnes `rownames(tab)[sel1] <- new2`

Modifier un objet ou son contenu

La syntaxe `obj[i] <- newvalue` (et ses variations) peut être utilisée pour tous les types d'objets indiçables. Mais il faut l'utiliser avec prudence !

Exemple : `fruits$Energie[1:10] <- 0`

Que s'est-il passé ? **Au secours !!!!**

Pour revenir en arrière : `data("fruits", package = "minidebuter")`

Extraction avec des noms

Exemple :

- Pour extraire l'énergie : `fruits[, "Energie"]`,
- Pour extraire le groupe : `fruits[, "groupe"]`,
- Pour extraire l'énergie et le groupe : `fruits[, c("Energie", "groupe")]`,
- Pour enlever le groupe : `fruits[, -"groupe"]` ?

Bilan

Mode d'extraction	Exemples
Indices	`fruits[, 2]`
Booléens	`fruits[fruits$nom == "Abricot", ]`
Noms	`fruits$nom` ou `fruits[,"nom"]`

Exercice

Lister le maximum de façons possibles d'extraire du tableau `fruits` les fruits crus sucrés riches en Vitamine C !

Construire ses propres objets

Vecteurs et facteurs

- La fonction `c()` permet de combiner des valeurs dans un vecteur. Attention, tout doit être du même “type” !
- La fonction `seq` permet de créer des suites.
- La fonction `rep` permet de créer des vecteurs en répétant des valeurs. Ex: `rep(c("a", "b"), c(3, 4))`

Les facteurs sont une particularité de R !

- On les crée avec la fonction `factor` ou `as.factor`
- Par exemple : `factor(fruits$groupe)`

Matrices et tableaux

- Les fonctions `matrix`, `rbind` et `cbind` pour créer des matrices. Attention, tout doit être du même “type” !
- Les fonctions `data.frame` ou `as.data.frame` pour créer des tableaux, les colonnes ne contiennent pas nécessairement le même type de données.
- Ou bien les fonctions `tibble` et `tribble` (avancé)

Ajouter des noms

Directement à la création de l'objet. Ex: `x <- c(a = 1, b = 2)`,`d <- data.frame(a = 1:26, b = letters)`

Ou bien après la création de l'objet :

- `names(obj) <- lesNoms` pour un vecteur
- `rownames(obj) <- lesLignes` pour les lignes d'un tableau ou d'une matrice,
- `colnames(obj) <- lesColonnes` pour les colonnes d'un tableau ou d'une matrice.

Exercice

Créez un facteur à partir des groupes de fruits, puis testez la commande suivante :

```
factor(fruits$groupe, levels = c("secs", "compote", "crus", "exotique"))
```

Que se passe-t-il ? Sauvez le résultat dans un objet et faites un diagramme en bâton avec ! Commentez !

Estimation ponctuelle

Définition

Il s'agit d'estimer un caractéristique statistique d'un ensemble de données avec une seule valeur.

Paramètre	Grandeur statistique	Commande
Position	Moyenne	`mean`
Position	Médiane	`median`
Position	Minimum	`min`
Position	Maximum	`max`
Dispersion	Variance	`var`
Dispersion	Ecart-type	`sd`
Dispersion	Intervalle inter-quartiles	`IQR`
Lien	Covariance	`cov`
Lien	Corrélation	`cor`

Rappel : la covariance

Permet de mesurer le degré de co-variation de deux variables :

$$\mathrm{cov}(x, y) = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - m_x)\left(y_i - m_y\right)$$

Rappel : corrélation de Pearson

C’est une covariance normalisée entre -1 et 1 !

$$\mathrm{cor}(x, y) = \frac{\mathrm{cov}(x, y)}{\sqrt{\mathrm{var}(x)}\sqrt{\mathrm{var}(y)}}$$

Rappel : corrélation de Spearman

C'est la corrélation (de Pearson) calculée sur les rangs !

$$\rho = \text{cor}(r_x, r_y),$$

avec r_x le vecteur des rangs de x (`rank(x)`), et r_y le vecteur des rangs de y (`rank(y)`).

Rappel (?) : corrélation de Kendall

- Paire concordante : $\left(x_i < x_j \text{ et } y_i < y_j\right)$ OU $\left(x_i > x_j \text{ et } y_i > y_j\right)$
- Paire discordante : $\left(x_i < x_j \text{ et } y_i > y_j\right)$ OU $\left(x_i > x_j \text{ et } y_i < y_j\right)$

$$\tau = \frac{n_C - n_D}{n_0},$$

avec n_C le nombre de paires concordantes, n_D le nombre de paires discordantes et n_0 le nombre total de paires de points.

Exercice

Calculez

- la médiane de la teneur en sucres
- la moyenne de la teneur en eau
- l'écart-type de la teneur en eau

Appliquez la fonction `summary` aux données `fruits`.

- Calculez la corrélation de Pearson entre la teneur en eau et la teneur en sucres,
- Calculez la corrélation de Spearman

Les fonctions astucieuses

- `summary` pour obtenir des statistiques
- `str` pour la structure des données
- `table` pour faire des tables de comptage
- `seq_along` pour créer un vecteur d'indices de même longueur qu'un vecteur donné

D'autres fonctions très utilies

- `sum` pour calculer la somme de nombres
- `sort`, `order` et `rank` pour ordonner, et calculer les rangs
- `rowSums` et `colSums` pour calculer les sommes des lignes et colonnes d'une table,
- `rowMeans` et `colMeans` pour calculer les moyennes des lignes et colonnes d'une table,

Les graphes de base

- `barplot` : diagrammes en bâtons
- `hist` : histogrammes
- `plot` : nuages de points

La fonction `barplot`

Permet de réaliser des diagrammes en bâtons :

```
barplot(table(fruits$groupe))
```

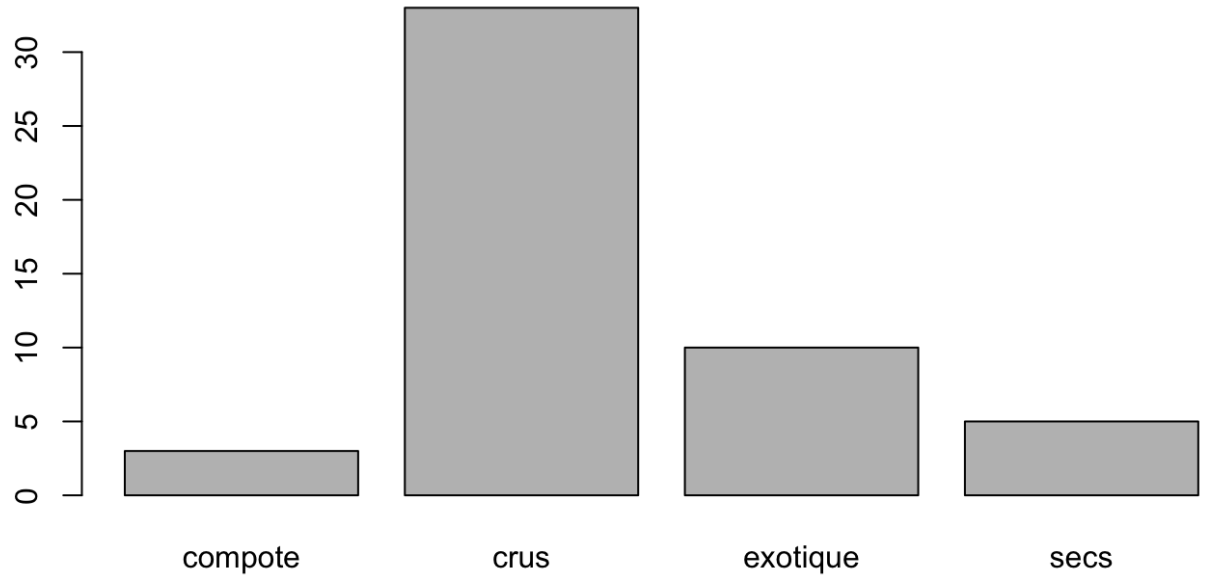

La fonction `hist`

Permet de réaliser des histogrammes :

```
hist(fruits$Eau)
```

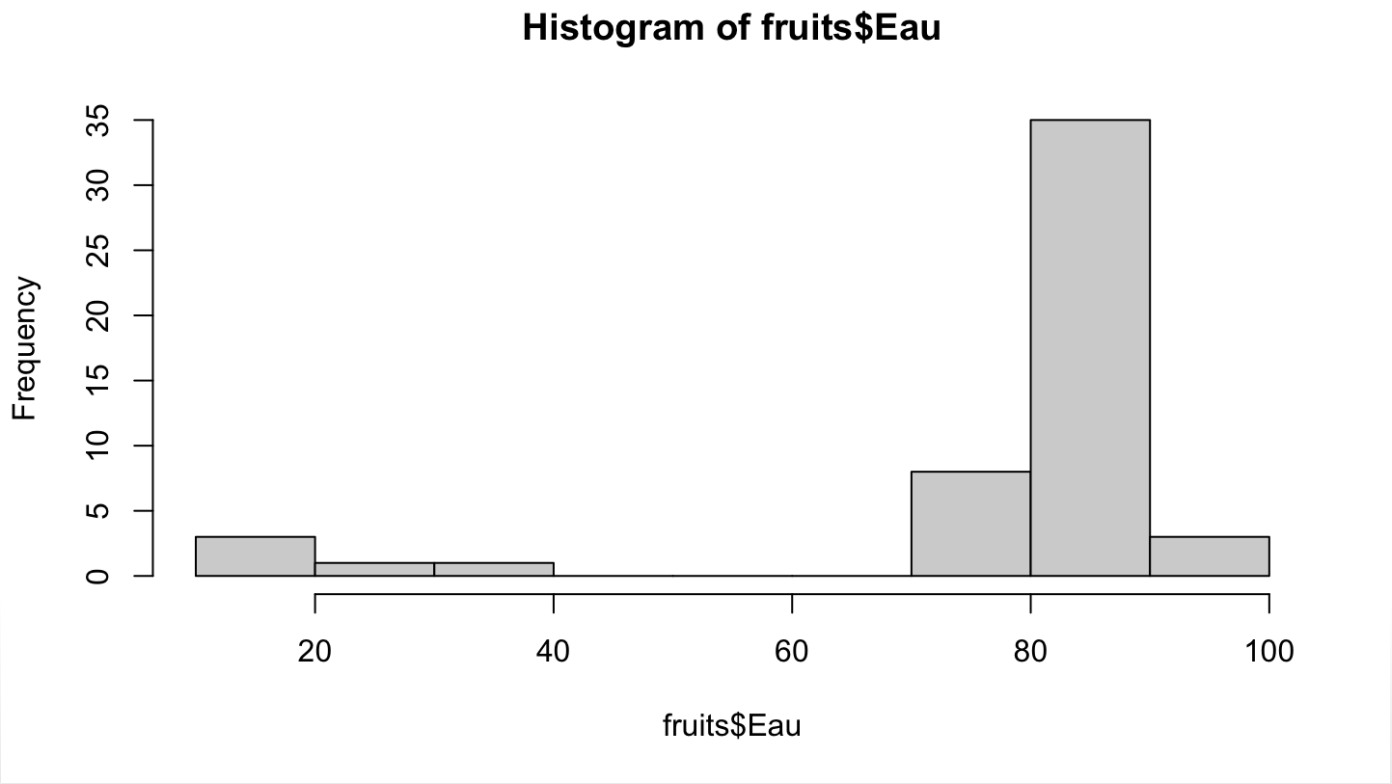

La fonction `plot`

Permet de tracer des nuages de points :

```
plot(fruits$Eau, fruits$Sucres)
```

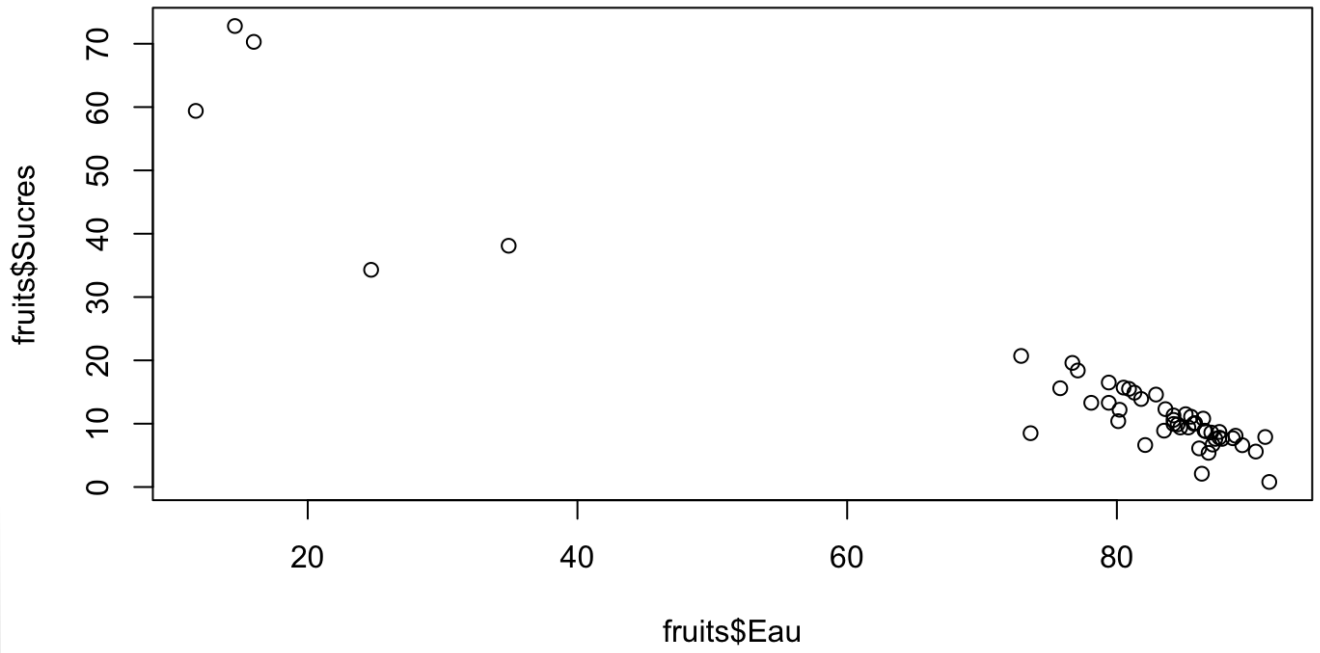

Exercice

Faire un histogramme de la teneur en Vitamine C des fruits crus.