

Les formats de fichiers de données



peut lire différents formats de données. Les principaux

formats rencontrés sont:

- Fichiers textes à valeurs séparées par un caractère spécial
- Fichiers Excel
- Fichier natif de R (Rda)

Un utilisateur peut vouloir enregister principalement des:

- données transformées dans R
- résultats d'analyses sous forme de tables
- sorties textes plus complexes
- graphiques.

Les exemples...

... se trouvent dans un dossier compressé qui contient les fichiers suivants :

Nom du fichier	Taille
data_io/1.tabular_simple.tsv	4486
data_io/2.tabular_complex_header.tsv	4608
data_io/3.only_one_col	487
data_io/4.tabular_no_header.tsv	2012
data_io/5.data_in_excel.xlsx	17858

Tables dans un fichier texte

la plus basique: fichier texte avec un séparateur

exemple:

```
groupe Energie Eau
                       Proteines
                                     Glucides
                                                  Lipides ....
nom
Abricot crus
            194
                  87.1 0.81
                               9.01 0.25
                                           6.7
                                                  1.3
                                                        1.7
            1010 24.7 2.88 59.1 0.5
                                           34.3
                                                 10.6
                                                       8.3
Abricot secs
                        81.3 0.94
                                   15.1
                                                 14.9 2.8
Ananas exotique
                  304
                                           0.25
```

lecture/ecriture avec les fonctions de bases de R

```
fruits <- read.table(file = "data_io/1.tabular_simple.tsv", header = T, sep = "\t")
write.table(x = fruits, file = "1.simpletabular.tsv", quote = F, sep = "\t", row.names = F)</pre>
```

Attention à ne pas écraser un fichier

» Il existe plusieurs variantes selon les fichiers de données

avec plusieurs ligne d'en-tête

exemple:

```
# nom : nom du fruit
# groupe : fruit sec, exotique, mangé crus ou en compote
# autres colonnes : valeurs nutritionelles
      groupe Energie Eau Proteines
                                      Glucides
                                                   Lipides ....
nom
Abricot crus 194
                   87.1 0.81
                                9.01 0.25
                                             6.7
                                                   1.3
                                                          1.7
                                             34.3 10.6 8.3
Abricot secs 1010 24.7 2.88 59.1 0.5
Ananas exotique
                   304 81.3 0.94 15.1
                                             0.25 14.9 2.8
```

```
fruits <- read.table(file = "2.tabular_complex_header.tsv", header = T, sep = "\t", skip=3)</pre>
```

avec une seule colonne

exemple:

Abricot
Ananas
Banane
Canneberge
Cerise
Citron
Clementine
CompoteMultiFruits

```
fruit_names <- scan(file = "3.only_one_col", what=character())</pre>
```

sans en-tête

```
Abricot crus 194 87.1 0.81 9.01 0.25
Abricot secs 1010 24.7 2.88 59.1 0.5
Ananas exotique 304 81.3 0.94 15.1 0.25
```

```
fruits <- read.table(
    file = "tabular_noheader.tsv",
    col.names = c("nom", "groupe", "Energie", "Eau", "Proteines", "Glucides", "Lipides"),
    sep = "\t"
)</pre>
```

ou

```
fruits <- read.table(file = "4.tabular_no_header.tsv", , header = T, sep = "\t")
names(fruits) <- c("nom", "groupe", "Energie", "Eau", "Proteines", "Glucides", "Lipides")</pre>
```

Fichier binaire de R

Les fichiers utilisés pour pouvoir sauvegarder et reprendre une session R plus tard.

```
load("data io/fruits.RData")
cela crée dans la session un ou des objets tels qu'ils ont été sauvegardés.
pour sauvegarder l'objet fruits:
save(fruits, file = "mySave.Rdata")
Pour sauvegarder tout une session de travail:
save.image(file = "mySession.RData")
ou
q("yes")
```

Lecture de fichier excel

Les données peuvent aussi être transmises sous forme d'un classeur excel. Il faut alors extraire la table d'intérêt dans la feuille qui le contient.

On utilise pour cela le package readxl qui fournis (entre autres) les fonctions

- read_excel
- read_xls
- et read_xlsx

Par exemple le classeur data_in_excel contient 3 feuilles:

```
library(readxl)
read_xlsx(path = "data_io/5.data_in_excel.xlsx", sheet = "fruits", skip = 3)
```

Ecriture de fichiers Excel

Pour écrire un fichier sous format "Excel", on utilise pour cela le package writexl.

Par exemple, on enregistre le tableau fruits_summary dans un fichier fruits_summary.xlsx avec la suite de commandes suivantes :

```
library(dplyr)
fruits_summary <- fruits %>%
  group_by(groupe) %>%
  summarize(
    MoyenneSucres = mean(Sucres),
    MoyenneLipides = mean(Lipides))

library(writexl)
write_xlsx(fruits_summary, path = "fruits_summary.xlsx")
```

Sorties graphiques

Quand nous voulons sauvegarder un graphe en ligne de commande, nous avons 2 moyens principaux:

Si le graphe a été généré avec les fonctions de base de R:

R fournit des fonctions pour enregistrer sous différents formats de fichier image (BMP, JPEG, PNG & TIFF). Elles fonctionnent toutes dans le même scénario:

```
png(filename="monBeauGraph.png", width = 960, height = 960 ) # remplacer l'affichage
# Code pour generer le graphique
dev.off() # finaliser le fichier
```

Attention: suivant les options "width" et "height", les textes et les points ne prendront pas la même place dans le fichier qu'à l'écran.

Si le graphe a été généré avec les fonctions de ggplot:

ggplot fournit la fonction ggsave. Par exemple, pour sauvegarder un plot enregistré dans la variable "g":

```
ggsave( filename="monBeauGraph.png, plot=g, device = png)
```